



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«ДОНСКОЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»
(ДГТУ)

ОТЧЁТ

по лабораторной работе № 6

«Исследование параметров text-to-image»

по дисциплине

«Искусственный интеллект в креативных технологиях»

Вариант 2

бриф 1 «афиша фестиваля робототехники» × фактор 2 «размер 512 → 384»

Выполнил: Яковенко Максим Михайлович

Группа: Т26ИИКТ-МИК11

1. Цель, бриф, фактор, гипотеза и допуск

1.1. Цель

Превратить подбор параметров генерации в контролируемый эксперимент: изменить один фактор, сохранить остальные условия, измерить отклик по четырём метрикам (сходство с запросом по CLIP, энергия границ, контраст, время генерации) на серии из пяти seed и сформулировать вывод в пределах проверенных условий, отделив статистическую значимость от практической пользы.

Вопрос варианта 2: **пригоден ли уменьшенный кадр 384×384 для черновиков афиши**, то есть можно ли по нему судить о чистовом кадре 512×512 и выигрывается ли при этом время.

1.2. Вариант 2

Номер варианта раскладывается по правилу $N = (\text{номер брифа} - 1) \cdot 6 + \text{номер фактора} = (1 - 1) \cdot 6 + 2 = 2$. В ноутбуке то же правило вычислено кодом: $c, k = (N - 1) // 6, (N - 1) \% 6$ даёт $c = 0$ (бриф 1) и $k = 1$ (фактор size_512_to_384).

Таблица 1 — Параметры варианта

Параметр	Значение
Бриф	1 «афиша фестиваля робототехники»: светящийся силуэт механической руки, глубокий синий и янтарный, чистая композиция, без текста, логотипов и людей
Фактор	2 «размер кадра, меньше»: режим А — 512×512, режим В — 384×384
Общие условия А и В	структурированный английский запрос (бриф), 1 шаг, guidance_scale = 0,0, вычисления float16, генератор шума на CPU
Серия seed	101, 102, 103, 104, 105
Метрики	сходство CLIP (100·cos, относительно английского брифа), энергия границ, контраст, время одного вызова генерации
Требования варианта	сравнивать метрики после приведения к одному масштабу; визуально проверить, что силуэт руки узнаваем и главный; вывод не переносить на другие модели

1.3. Гипотеза, записанная до запуска

Гипотеза и допуск записаны в журнал reports/journal.md и зафиксированы отдельным коммитом 057583a до первого выполнения ноутбука; в ноутбуке (раздел 4) они повторены без изменений. Из указаний был известен только режим А демонстрационного варианта (тот же бриф, 512, 1 шаг): CLIP 30,80 ($s = 1,39$).

Механизм, из которого выведены ожидания. SD Turbo получена состязательной дистилляцией (ADD, arXiv:2311.17042) на кадрах 512×512, карточка модели называет размер фиксированным. Кадр 384 технически допустим (латент 48×48 вместо 64×64), но сеть обучена строить композицию на сетке 64×64 за один шаг, поэтому ожидалось упрощение сцены; палитра и главный объект заданы текстом и должны сохраниться.

Таблица 2 — Ожидания по метрикам до запуска

Метрика	Ожидание	Обоснование
Сходство CLIP	снижение не больше 1,0; по 2s незначимо	процессор CLIP приводит любое изображение к 224×224, разрешение само по себе почти не влияет
Энергия границ, исходный размер	рост больше 10 %	метрика — средний градиент на пиксель; та же сцена на сетке 384 имеет более крутые перепады (до 512/384 ≈ 1,33 раза)
Энергия границ, один масштаб	в допуске или снижение	после приведения к одному размеру остаётся только эффект «меньше деталей»
Контраст	в пределах ±10 %; по 2s незначимо	σ яркости от масштаба не зависит, меняется лишь вместе с композицией
Время	снижение на 35–50 %; значимо по 2s	U-Net и декодер VAE обрабатывают 0,56 исходного числа пикселей; часть времени — постоянные накладные расходы

1.4. Практический допуск и его обоснование

Таблица 3 — Практический допуск (записан до запуска)

Метрика	Допуск	Обоснование
Сходство CLIP	±1,0 (абсолютно)	меньше разброса между seed (1,39 в демонстрационном варианте): сдвиг, неотличимый от смены seed, неважен
Энергия границ	±10 % от A	разница резкости 10 % между эскизами на глаз почти не различима
Контраст	±10 % от A	с 10 % начинает меняться «читаемость» силуэта на тёмном фоне
Время	±20 % от A	20 % — минимальная экономия на серии, ради которой стоит менять размер кадра

Правило классификации. Задача — черновик, по которому судят о чистовом кадре 512. Поэтому для CLIP рост больше +1,0 — «улучшение», падение больше −1,0 — «ухудшение»; для времени снижение больше 20 % — «улучшение», рост — «ухудшение»; для энергии границ и контраста выход за ±10 % **в любую сторону** — «ухудшение» (черновик перестаёт представлять чистовой кадр), внутри допуска — «нейтрально». Признак $|\Delta| > 2s$ оценивается отдельно и с допуском не смешивается.

Ожидаемый ответ (записан до запуска): кадр 384 пригоден для черновиков, если CLIP и контраст останутся в допуске, время снизится больше чем на 20 %, а силуэт механической руки на всех пяти seed останется узнаваемым главным объектом.

2. Данные, лицензии моделей и ограничения

2.1. Данные — тексты запросов

Данные синтетические: входом служат только тексты запросов из учебной библиотеки. Реальные люди, логотипы, названия производителей и материалы с неподтверждёнными правами не используются. Запрос обоих режимов — бриф 1 из списка L.BRIEFS библиотеки lab05_lib.py:

editorial poster concept for a robotics festival, glowing mechanical arm silhouette, deep blue and amber palette, clean composition, no text, no logo, no people

Русский перевод из библиотеки (M.RU[0]), приведён для читателя и в эксперименте не используется: «плакат-концепт для фестиваля робототехники, светящийся силуэт механической руки, глубокий синий и янтарный цвета, чистая композиция, без текста, без логотипа, без людей». Сходство CLIP в обоих режимах считается относительно английского брифа; в ноутбуке это проверено строкой `L.BRIEFS[c] == a_cfg["prompt"]` → True.

2.2. Лицензии моделей

- **stabilityai/sd-turbo** (ревизия b261bac6...) — файл LICENSE.md на закреплённой ревизии содержит Stability AI Community License Agreement: коммерческое использование разрешено организациям с годовым доходом менее 1 млн долларов США после регистрации у правообладателя, при распространении сохраняются уведомление о лицензии и указание «Powered by Stability AI»; действует политика допустимого использования (Acceptable Use Policy). «Открытая» здесь означает доступность весов, а не соответствие критериям открытого ПО.
- **openai/clip-vit-base-patch32** (ревизия 3d74acf9...) — модель OpenAI; исходный код CLIP опубликован под лицензией MIT, а карточка модели относит её к исследовательским результатам и выводит любое развёрнутое (deployed) применение за рамки назначения. В работе CLIP используется только как измерительный инструмент в учебном эксперименте.
- Работа учебная и некоммерческая; сгенерированные изображения — концепты афиши, а не иллюстрации реальных устройств, и не публикуются как самостоятельные произведения.

Ограничения. Один бриф и одна модель; пять seed дают грубую оценку s ; метрики зависят от размера кадра; CLIP обучен преимущественно на английских текстах и видит изображение в 224×224. Подробно — в разделах 6.7 и 6.8.

3. Среда выполнения

Таблица 4 — Среда, версии и модели

Параметр	Значение
Платформа	Google Colab, ускоритель «Графический процессор T4»; Linux 6.6, 2 vCPU, 13 ГБ ОЗУ
GPU	Tesla T4; CUDA доступна, запасной путь на CPU не применялся
Python и пакеты	Python 3.13.15; torch 2.11.0+cu130; diffusers 0.40.0; transformers 5.16.1; accelerate 1.15.0; huggingface_hub 1.33.0; safetensors 0.8.0; tokenizers 0.23.2; numpy 2.1.3; scipy 1.16.3; Pillow 11.3.0
Модель генерации	stabilityai/sd-turbo, ревизия b261bac6fd2cf515557d5d0707481eafa0485ec2; файлы fp16, вычисления float16 на cuda:0
Модель метрики	openai/clip-vit-base-patch32, ревизия 3d74acf9a28c67741b2f4f2ea7635f0aaf6f0268, cuda:0

Параметр	Значение
Учебные библиотеки	lab05_lib.py 6447 байт, SHA-256 4eb17650...; lab06_lib.py 6580 байт, SHA-256 c6d8473c... — совпадают с указаниями
Время	загрузка SD Turbo 23,1 с и CLIP 16,4 с (с первым скачиванием весов); серия варианта 7,7 с; весь ноутбук 8,1 мин

Отличие от проверенной конфигурации указаний одно: сборка torch 2.11.0 под CUDA 13.0 (+cu130) вместо CUDA 12.8. Версии diffusers и transformers приведены к указанным первой ячейкой (доустановлен transformers 5.16.1). Сверка с демонстрационным вариантом (раздел 6.5) показала, что на результат это практически не повлияло. Предупреждения в выводе ячеек (устаревшие аргументы torch_dtype и local_dir_use_symlinks, переименованный класс Siglip2ImageProcessorFast, запросы к Hugging Face без токена) относятся к библиотекам и на вычисления не влияют.

4. Ход работы

Ноутбук Яковенко_Максим_Михайлович_Вариант_2_ЛР_6.ipynb построен по плану раздела 5 указаний: каждому шагу соответствует свой раздел с пояснением перед кодом. Все 23 ячейки кода выполнены по порядку без ошибок (счётчики выполнения 1...23 подряд, ячеек с ошибками нет).

Таблица 5 — Соответствие разделов ноутбука шагам плана

Шаг плана	Раздел ноутбука	Наблюдаемый результат
1. Подготовка среды	1–3	версии пакетов, Tesla T4, SHA-256 библиотек совпали
2. Гипотеза и допуск	4 (и журнал, коммит 057583a)	таблица допусков и ожиданий
3. Загрузка модели и CLIP	5	23,1 с и 16,4 с; float16, cuda:0
4. Режимы А и В	6	словари различаются только полем size
5. variant_summary, таблица	7	таблица метрик и значения по seed
6. Сравнительный лист	8	comparison.png, series_seeds.png, метрики на одном масштабе
7. Классификация по допуску	9	классификация, расхождения 2s и допуска, чувствительность
8. Намеренная ошибка	10	SHA-256 совпали, CFG выключен
сверх плана	11	демонстрационный вариант 1 воспроизведён и сопоставлен
9. Паспорт и отчёт	12–17	results.json, SHA-256 артефактов, вывод, паспорт

Ниже — ключевые фрагменты кода; после каждого — что он делает и зачем. Библиотеки преподавателя не редактировались.

Шаг 1. Версии пакетов.

```
TORCH_V = installed_version("torch") # по метаданным пакета, без импорта
PINS = ({ "diffusers": "0.40.0", "transformers": "5.16.1" } if at_least(TORCH_V, (2, 6))
        else { "diffusers": "0.32.2", "transformers": "4.48.3" })
todo = [f"{k}=={v}" for k, v in PINS.items() if installed_version(k) != v]
if todo:
    subprocess.run([sys.executable, "-m", "pip", "install", "-q", *todo], check=True)
```

Что делает. определяет версию torch по метаданным пакета и доустанавливает только те из diffusers и transformers, что отличаются от проверенной конфигурации указаний. В Colab установлен лишь transformers 5.16.1. Строка «Доустановлено: ничего» в выводе относится к следующему резервному циклу проверки импорта.

Зачем. числа можно сравнить с указаниями только при тех же версиях; torch не трогается, чтобы не сломать сборку под GPU Colab.

Шаг 1. Контроль целостности библиотек.

```
EXPECTED = {"lab05_lib.py": (6447, "4eb17650"), "lab06_lib.py": (6580, "c6d8473c")}
for name, (size, prefix) in EXPECTED.items():
    data = (WORK / name).read_bytes()
    h = hashlib.sha256(data).hexdigest()
    LIB_SHA[name] = dict(bytes=len(data), sha256=h,
```

```

        matches_methodical=(len(data) == size and h.startswith(prefix)))
assert all(v["matches_methodical"] for v in LIB_SHA.values())

```

Что делает. сравнивает размер и SHA-256 библиотек, записанных ячейками `%%writefile`, с разделом 6 указаний; при несовпадении ноутбук останавливается.

Зачем. работает ровно тот код, который проверял преподаватель.

Шаг 1. Проверка устройства.

```

CUDA = torch.cuda.is_available()
if CUDA:
    import lab05_lib as L
    import lab06_lib as M          # библиотеки как есть: cuda, float16
else:
    ...                          # запасной путь: "cuda" -> "cpu", float16 -> float32
    только в памяти
assert M.L is L

```

Что делает. на GPU импортирует библиотеки как есть; запасной путь (замены в памяти) включается только без CUDA. В этом запуске он не применялся (`adaptation.applied = false`).

Зачем. условия совпадают с указаниями (`cuda, float16`); `M.L is L` гарантирует, что `lab06_lib` использует тот же `lab05_lib`.

Шаги 3–4. Модели и режимы A, B.

```

pipe = L.load_pipe()                # SD Turbo, ревизия b261bac6..., float16, cuda
clip = M.load_clip()                # CLIP ViT-B/32, ревизия 3d74acf9...
N = 2
c, k = (N - 1) // 6, (N - 1) % 6    # c = 0 (бриф 1), k = 1 (size_512_to_384)
a_cfg, b_cfg = M.settings(M.FACTORS[k], c)
diff = [key for key in a_cfg if a_cfg[key] != b_cfg[key]]
assert diff == ["size"], "изменено не ровно одно поле"

```

Что делает. загружает обе модели закреплённых ревизий и проверяет, что режимы A и B различаются только полем `size` (512 и 384); `prompt, steps = 1, guidance = 0.0` одинаковы.

Зачем. критерий успеха — изменён ровно один фактор; проверка кодом надёжнее внимательности.

Шаг 5. Серия seed с сохранением значений по каждому seed.

```

RECORDS = []
_measure = M.measure
def measure_logged(pipe, clip, cfg, c, seed):
    met, img = _measure(pipe, clip, cfg, c, seed)          # исходная функция, те же
    аргументы
    RECORDS.append(dict(mode="A" if cfg == a_cfg else "B", seed=seed, img=img,
                        png_sha256=L.sha(L.png_bytes(img)), **met))
    return met, img
M.measure = measure_logged
try:
    res = M.variant_summary(pipe, clip, N)
finally:
    M.measure = _measure

```

Что делает. `variant_summary` делает два прогревочных вызова, затем для каждого `seed` генерирует A и B, считает четыре метрики (время — только вызов генерации) и сводку: среднее, `s` по A, Δ , $|\Delta|/s$, признак 2s. На время вызова `M.measure` подменяется обёрткой,

которая вызывает исходную функцию и запоминает метрики, изображение и SHA-256 его PNG.

Зачем. функция возвращает только сводку, а для таблицы по seed, сравнения на одном масштабе и листа серии нужны отдельные значения и изображения. Пересчёт сводки по записанным значениям (`np.isclose, ddof = 1`) подтвердил, что обёртка вычисления не изменила.

Шаг 7. Классификация по допуску.

```
TOL = {"clip": ("abs", 1.0), "edge": ("rel", 0.10), "contrast": ("rel", 0.10), "seconds": ("rel", 0.20)}
DIRECTION = {"clip": +1, "seconds": -1, "edge": 0, "contrast": 0}
def verdict(metric, a, d, scale=1.0):
    kind, tol = TOL[metric]
    tol = tol * scale * (abs(a) if kind == "rel" else 1.0)
    if abs(d) <= tol:
        return "нейтрально"
    if DIRECTION[metric] == 0:
        return "ухудшение"
    return "улучшение" if d * DIRECTION[metric] > 0 else "ухудшение"
```

Что делает. переводит записанный до запуска допуск в код: абсолютный для CLIP, относительный к A для остальных; для энергии границ и контраста любой выход за допуск — «ухудшение». Параметр `scale` используется для проверки чувствительности: классификация повторяется при допуске $\times 0,5$ и $\times 2$, и для каждой метрики вычисляется порог смены ответа $|\Delta|$ (или $|\Delta|/A$).

Зачем. классификация идёт по правилу, зафиксированному заранее, и не подбирается под результат.

Шаг 6. Сравнительный лист и проверка повторяемости.

```
full = [L.generate(pipe, cfg["prompt"], 101, steps=cfg["steps"], guidance=cfg["guidance"],
                  size=cfg["size"])[0] for cfg in (a_cfg, b_cfg)]
pair = [im.resize((384, 384)) for im in full]
sheet = Image.new("RGB", (768, 384))
sheet.paste(pair[0], (0, 0)); sheet.paste(pair[1], (384, 0))
sheet.save(ART / "comparison.png")
REPRO_101 = {mode: L.sha(L.png_bytes(im)) == rec101[mode]["png_sha256"] for mode, im in
zip("AB", full)}
```

Что делает. код раздела 6.2 указаний: заново генерирует seed 101 в режимах A и B, приводит оба к 384×384 и ставит рядом; затем сравнивает SHA-256 с изображениями серии — `{'A': True, 'B': True}`. Отдельная ячейка собирает из изображений серии лист `series_seeds.png`.

Зачем. совпадение бит в бит подтверждает детерминированность генерации; лист серии нужен, чтобы визуальная оценка опиралась на пять seed, а не на один.

Шаг 6. Метрики на одном масштабе (требование варианта 2).

```
A384 = [im.resize((384, 384), Image.LANCZOS) for im in imgs["A"]]
B512 = [im.resize((512, 512), Image.LANCZOS) for im in imgs["B"]]
for metric, fn in (("edge", M.edge_energy), ("contrast", M.contrast)):
    COMMON[f"{metric}@384"] = summarize([fn(x) for x in A384], [fn(x) for x in imgs["B"]])
    COMMON[f"{metric}@512"] = summarize([fn(x) for x in imgs["A"]], [fn(x) for x in B512])
scale_only = summarize([M.edge_energy(x) for x in imgs["A"]], [M.edge_energy(x) for x in A384])
```

Что делает. пересчитывает энергию границ и контраст после приведения к общему размеру: основное сравнение — оба при 384 (уменьшение А ничего не выдумывает), контрольное — оба при 512; последняя строка — «чистый» эффект масштаба на одном и том же изображении А.

Зачем. энергия границ — градиент на пиксель, и та же картинка на меньшей сетке даёт больший градиент только из-за масштаба; без этого шага его нельзя отделить от изменения содержания.

Шаг 8. Намеренная ошибка демонстрационного варианта.

```
x0 = L.generate(pipe, p, 101, guidance=0.0)[0]
x1 = L.generate(pipe, p, 101, guidance=1.0)[0]
print(L.sha(L.png_bytes(x0)) == L.sha(L.png_bytes(x1)), pipe.do_classifier_free_guidance)
x3 = L.generate(pipe, p, 101, guidance=3.0)[0]
print(pipe.do_classifier_free_guidance, round(L.psnr_db(x0, x3), 2))
```

Что делает. код раздела 6.2 указаний: сравнивает SHA-256 изображений при guidance_scale 0,0 и 1,0, печатает признак do_classifier_free_guidance, затем повторяет при 3,0 и считает PSNR относительно 0,0.

Зачем. даёт проверяемый признак (SHA-256 и флаг) вместо визуального впечатления.

Сверх плана. Воспроизведение демонстрационного варианта 1.

```
DEMO_REF = {"clip": (30.796, 1.394, 30.292, -0.504, 0.36, False), ...} # таблица 6.3
указаний
res1 = M.variant_summary(pipe, clip, 1)
for m, a, s, b, d, ratio, sig in res1["rows"]:
    ra, rs, rb, rd, rr, rsig = DEMO_REF[m]
    v_ref, v_here = [("в допуске" if verdict(m, x, y) == "нейтрально" else "вне допуски")
                     for x, y in ((ra, rd), (a, d))]
    conclusion_match = (rsig == sig) and (v_ref == v_here)
```

Что делает. запускает ту же функцию для варианта 1 (шаги 1 → 4) и сравнивает с таблицей указаний расхождение значений, признак 2s и ответ по допуску; время — по отношению В/А. В конце ноутбука без изменений выполнен и скрипт преподавателя lab06_demo.py (в подпапке demo/).

Зачем. проверяет, что среда даёт те же числа, что у преподавателя (продвинутый уровень блока «Артефакт и воспроизводимость»).

5. Результаты

Все числа ниже взяты из вывода ячеек ноутбука и файла `artifacts/results.json`; округление только при выводе.

5.1. Таблица метрик по серии seed 101...105 (шаг 5)

Таблица 6 — `variant_summary(pipe, clip, 2)`: режим А (512), s режима А, режим В (384)

Метрика	А	s	В	Δ	Δ/A	$ \Delta /s$	$ \Delta > 2s$	по допуску
сходство CLIP	30,80	1,43	28,54	−2,26	−7,3 %	1,58	нет	ухудшение
энергия границ	0,0457	0,0070	0,0491	+0,0034	+7,4 %	0,49	нет	нейтрально
контраст	0,1923	0,0225	0,2187	+0,0264	+13,7 %	1,17	нет	ухудшение
время, с	0,2801	0,0040	0,1857	−0,0944	−33,7 %	23,42	да	улучшение

5.2. Значения по отдельным seed

Таблица 7 — Метрики каждого изображения серии

seed	режим	размер	CLIP	энергия границ	контраст	время, с	SHA-256 PNG
101	А	512	30,31	0,0480	0,1569	0,283	84db2534b3e6...
101	В	384	26,76	0,0449	0,2258	0,185	256158c9736e...
102	А	512	32,94	0,0471	0,2191	0,278	0d0d796d3cf4...
102	В	384	25,48	0,0513	0,1514	0,186	76587fa5d909...
103	А	512	31,33	0,0554	0,1977	0,274	d0a3ff677d89...
103	В	384	27,45	0,0462	0,1948	0,185	88e90f270113...
104	А	512	30,29	0,0395	0,1967	0,281	82a2b32b5aa5...
104	В	384	32,82	0,0538	0,3331	0,186	a61e48e29009...
105	А	512	29,12	0,0383	0,1910	0,284	21897cc9e657...
105	В	384	30,19	0,0492	0,1886	0,186	11499c52b093...

Время стабильно (А 0,274–0,284 с, В 0,185–0,186 с), остальные метрики меняются между seed в разные стороны: CLIP в В ниже у seed 101–103 (на 3,6; 7,5; 3,9) и выше у 104, 105 (на 2,5 и 1,1). Разброс в В больше: s CLIP 2,95 против 1,43, s контраста 0,069 против 0,022.

5.3. Энергия границ и контраст на одном масштабе (шаг 6)

Таблица 8 — Сравнение после приведения к одному масштабу (Lanczos)

Сравнение	А	В	Δ/A	$ \Delta /s$	$ \Delta > 2s$	по допуску
энергия границ, оба при 384	0,0504	0,0491	−2,6 %	0,16	нет	нейтрально
энергия границ, оба при 512	0,0457	0,0436	−4,5 %	0,30	нет	нейтрально
контраст, оба при 384	0,1901	0,2187	+15,1 %	1,23	нет	ухудшение
контраст, оба при 512	0,1923	0,2183	+13,5 %	1,15	нет	ухудшение
энергия границ: только масштаб (А 512 → А 384)	0,0457	0,0504	+10,3 %	0,68	нет	—

Энергия границ на одном масштабе снизилась на 2,6 % (384) и 4,5 % (512) — в допуске. Рост +7,4 % на исходном размере раскладывается на эффект масштаба +10,3 % и изменение содержания −2,6 %: $1,103 \times 0,974 \approx 1,074$. Контраст на обоих масштабах вырос одинаково (+15,1 и +13,5 %), то есть его сдвиг с масштабом не связан.

5.4. Сравнительный лист (шаг 6)




Рисунок 1 — *comparison.png*: seed 101, слева режим А (512, уменьшено до 384), справа режим В (384)



Рисунок 2 — *series_seeds.png*: вся серия, верхний ряд — режим А (512), нижний — режим В (384), seed 101...105 слева направо

Таблица 9 — Визуальное описание серии (рисунок 2)

seed	Режим А (512)	Режим В (384)
101 (рисунок 1)	робот анфас, синий фон, янтарные детали; в углу орнамент, похожий на буквы (псевдотекст при no text)	рука-машина аркой, город и светящийся диск, палитра сместилась к фиолетово-коричневой
102	робот в янтарном круге-ореоле	крупный манипулятор по диагонали на синем звёздном фоне — ближе всего к «силуэту механической руки»
103	сложная фигура с несколькими манипуляторами	тёмный робот в янтарной рамке («картина в картине»), светло-голубой фон

seed	Режим А (512)	Режим В (384)
104	синий робот на янтарном фоне	тёмный робот на светлом небе над пустыней, сверху оранжевая полоса, слева тёмное поле
105	промышленный манипулятор на голубом фоне	робот с рукой на тёмном фоне, по краям янтарные шестерни

1. Главный объект — механическая рука или робот с манипуляторами — узнаваем и стоит в центре кадра на всех десяти изображениях, в режиме В — на 5 из 5. В обоих режимах модель чаще рисует целого робота, чем отдельную руку; это свойство модели и брифа, а не фактора.
2. Для одного seed композиции А и В не совпадают ни в одном из пяти случаев.
3. В В меньше мелких деталей (шестерни, проводка, фактура фона), силуэты крупнее и проще; в двух кадрах В из пяти (103, 104) появились рамки и поля, в А явных рамок нет.
4. Палитра «синий и янтарный» в В сохранилась у seed 102, 103, 105; у 101 она сместилась к фиолетовому, у 104 фон светлый и синий почти исчез.

6. Анализ

6.1. Классификация по допуску (шаг 7)

Таблица 10 — Ожидание, критерий $2s$ и классификация по допуску

Метрика	Ожидание до запуска	$ \Delta > 2s$	По допуску	Согласие $2s$ и допуска
сходство CLIP	нейтрально	нет	ухудшение	вне допуска, но не значимо по $2s$
энергия границ	ухудшение (рост $> 10\%$)	нет	нейтрально	согласны
контраст	нейтрально	нет	ухудшение	вне допуска, но не значимо по $2s$
время, с	улучшение	да	улучшение	согласны

По правилу, записанному до запуска, кадр 384 как черновик чистового кадра 512 **не принимается**: выполнены два условия из четырёх (время и узнаваемость объекта), не выполнены условия по CLIP и контрасту.

6.2. Статистическая и практическая значимость

Критерий $|\Delta| > 2s$ отвечает на вопрос, выходит ли эффект за разброс между seed, а допуск — важен ли эффект для задачи. В этом варианте они совпали для времени (оба «да») и энергии границ (оба «нет») и разошлись для CLIP и контраста: изменение больше допуска, но меньше двух s . Пяти seed не хватает, чтобы отличить такой эффект от разброса: ухудшение нельзя ни утверждать, ни исключить.

Неопределённость здесь даже больше, чем показывает $|\Delta|/s$: критерий опирается на s режима А, а в режиме В разброс вдвое (CLIP) и втрое (контраст) больше. Стандартная ошибка разности средних для CLIP с учётом обоих разбросов — $\sqrt{(1,43^2/5 + 2,95^2/5)} \approx 1,47$, то есть $\Delta = -2,26$ составляет около 1,5 стандартной ошибки. У времени, наоборот, $s = 0,004$ с и порог $2s$ крошечный (0,008 с): значимость гарантирована, а практическую важность определяет только допуск.

6.3. Чувствительность вывода к допуску

Таблица 11 — Классификация при допуске $\times 0,5$, $\times 1$ и $\times 2$

Метрика	$\times 0,5$	$\times 1$ (основной)	$\times 2$	Порог смены ответа	в долях допуска
сходство CLIP	ухудшение	ухудшение	ухудшение	2,26 (абс.)	2,26
энергия границ	ухудшение	нейтрально	нейтрально	7,4 %	0,74
контраст	ухудшение	ухудшение	нейтрально	13,7 %	1,37
время, с	улучшение	улучшение	нейтрально	33,7 %	1,69

Основной допуск после запуска не менялся. Ответ на вопрос варианта устойчив во всём диапазоне $\times 0,5 \dots \times 2$: условие по CLIP нарушается при любом допуске меньше 2,26, то есть даже при удвоенном (2,0). Меняются только сопутствующие ответы: при допуске $\times 0,5$ энергия границ (+7,4 %) тоже становится «ухудшением»; при $\times 2$ контраст (+13,7 %) становится «нейтрально», но и время ($-33,7\% < 40\%$) — тоже «нейтрально», то есть кадр 384 теряет и своё единственное практическое преимущество. Ответ «пригоден» дало бы

только сочетание: допуск CLIP не меньше 2,26, контраста не меньше 13,7 %, времени меньше 33,7 %.

6.4. Сопоставление с гипотезой

Таблица 12 — Гипотеза (коммит 057583a) и результат

Предсказание	Получено	Итог
CLIP снизится не больше чем на 1,0, по 2s незначимо	-2,26, $ \Delta /s = 1,58$	не подтвердилось по величине; незначимость подтвердилась
энергия границ на исходном размере вырастет больше чем на 10 %	+7,4 %	не подтвердилось
энергия границ на одном масштабе — в допуске или ниже	-2,6 % (384), -4,5 % (512)	подтвердилось
контраст в пределах ± 10 %, по 2s незначимо	+13,7 %, $ \Delta /s = 1,17$	не подтвердилось по допуску; незначимость подтвердилась
время снизится на 35–50 %, значимо по 2s	-33,7 %, $ \Delta /s = 23,4$	подтвердилось по направлению, значимости и классу; величина чуть ниже диапазона
силуэт руки узнаваем на всех пяти seed	5 из 5	подтвердилось

Энергия границ. Механизм верен — эффект масштаба дал +10,3 %. Ошибочной оказалась оценка, что упрощение деталей действует «слабее»: оно сопоставимо (-2,6 %) и погасило около четверти роста от масштаба.

Время. В занимает 0,66 времени А при доле пикселей 0,56: постоянные накладные расходы вызова (кодирование текста, запуск ядер, перенос результата) больше, чем я закладывал.

Контраст. Механизм «σ яркости не зависит от масштаба» подтвердился: на двух масштабах сдвиг одинаков. Весь сдвиг дал один кадр со светлым небом (seed 104: 0,333 против 0,197); без него контраст В на 0,6 % ниже А, медиана — на 1 % ниже.

CLIP. Объект сохранился на всех кадрах, но CLIP упал у трёх seed из пяти; причины разобраны в разделе 6.7.

6.5. Воспроизведение демонстрационного варианта и сопоставление с указаниями

Демонстрационный вариант 1 (бриф 1, шаги 1 → 4) выполнен той же функцией `M.variant_summary(pipe, clip, 1)` в том же сеансе и сопоставлен с таблицей раздела 6.3 указаний.

Таблица 13 — Демонстрационный вариант: указания против этого запуска

Метрика	А / В в указаниях	А / В здесь	Расхождение	2s: указ. / здесь	Допуск: указ. / здесь
сходство CLIP	30,80 / 30,29	30,80 / 30,29	А +0,01 %, В +0,00 %	нет / нет	в допуске / в допуске
энергия границ	0,0457 / 0,0920	0,0457 / 0,0920	А -0,09 %, В -0,03 %	да / да	вне допуски / вне допуски
контраст	0,1923 / 0,2778	0,1923 / 0,2779	А -0,01 %, В +0,02 %	да / да	вне допуски / вне допуски
время, с	0,2854 / 0,5266	0,2928 / 0,5353	В/А 1,83 (указ. 1,85)	да / да	вне допуски / вне допуски

Значения CLIP, энергии границ и контраста совпали с указаниями с расхождением не больше 0,1 %, выводы по критерию 2s и по допуску совпали по всем четырём метрикам. Отличие в третьем знаке есть у s сходства CLIP режима A (1,431 против 1,394): отдельные значения по seed немного различаются, вероятно из-за сборки torch под CUDA 13.0. Время сравнивается по отношению B/A: 1,83 против 1,85. Скрипт преподавателя lab06_demo.py дал те же значения.

6.6. Намеренная ошибка: `guidance_scale = 1,0`

Симптом. Ожидание, что `guidance_scale = 1,0` «слегка включает» управление запросом у SD Turbo.

Наблюдение. Изображение при 1,0 совпало с изображением при 0,0 бит в бит (SHA-256 равны), `pipe.do_classifier_free_guidance = False`. При 3,0 признак True, изображение заметно другое: PSNR относительно 0,0 — 11,61 дБ (в указаниях 11,6 дБ). Изображение при 0,0 совпало с изображением A seed 101 из серии.

Диагностика. В Diffusers управление без классификатора включается только при `guidance_scale > 1`. При значениях от 0 до 1 выполняется один проход сети с текстом, и параметр не влияет на результат. Даже формально при $w = 1$ смесь $\epsilon_u + w \cdot (\epsilon_c - \epsilon_u)$ равна ϵ_c , то есть совпадает с предсказанием без управления.

Исправление. Изучать влияние guidance у SD Turbo можно только при значениях больше 1, то есть вне рекомендованного режима модели (по карточке — 0,0); результат нельзя переносить на модели с обычным управлением без классификатора.

6.7. Альтернативные объяснения и ограничения метрик

1. **Снижение CLIP:** (а) потеря соответствия брифу из-за упрощения деталей; (б) смена фона и стиля (город и фиолетовая палитра у seed 101, рамка у 103); (в) случайность — около 1,5 стандартной ошибки. Против (а): порядок кадров по CLIP расходится с визуальной оценкой — кадр B 102, на глаз ближе всего к брифу, имеет наименьшее сходство (25,48), кадр B 104 со светлым небом — наибольшее (32,82). Различить (а)–(в) пятью seed нельзя.
2. **Рост контраста** — свойство композиции одного кадра (светлое небо при тёмном роботе), а не размера: на одном масштабе сдвиг тот же, без seed 104 его нет.
3. **Энергия границ** на исходном размере смешивает масштаб и содержание; кроме того, она растёт и от шума, и от артефактов, поэтому даже её рост не означал бы «больше полезных деталей».
4. **Время** зависит от состояния GPU: режим A в тех же условиях занял 0,280 с в серии варианта и 0,293–0,294 с в повторах демонстрационного варианта (+5 %); эффект –33,7 % намного больше, но абсолютные значения не переносятся.
5. **Ограничения метрик в целом.** CLIP видит изображение только в 224×224 и оценивает соответствие тексту в своём представлении, а не эстетику и точность деталей; энергия границ и контраст — статистики яркости; ни одна метрика не отвечает на вопрос, хороша ли афиша.

6.8. Угрозы валидности

1. **Статистическая.** $n = 5$; s оценено только по режиму А, разброс В больше; выводы по CLIP и контрасту не подтверждены статистически.
2. **Конструктивная.** Метрики не измеряют качество черновика; визуальная оценка выполнена одним наблюдателем (автором) без слепого протокола.
3. **Внутренняя.** Изменён ровно один фактор (проверено кодом); А и В чередуются внутри каждого seed после прогрева, поэтому медленный дрейф состояния GPU действует на оба режима одинаково.
4. **Внешняя.** Одна модель (обучена на 512), один бриф, один тип GPU, сборка torch под CUDA 13.0; приведение к одному масштабу зависит от фильтра (Lanczos).

7. Вывод

Наблюдение. Для брифа 1 уменьшение кадра SD Turbo с 512×512 до 384×384 (1 шаг, guidance 0,0, seed 101...105, Tesla T4, float16) дало:

1. время $-33,7\%$ — значимо и вне допуска: **улучшение**;
2. сходство CLIP $-2,26$ и контраст $+13,7\%$ (весь сдвиг — seed 104) — вне допуска, но по 2s незначимо: **ухудшение**, статистически не подтверждённое;
3. энергия границ $+7,4\%$ (на одном масштабе $-2,6\%$) — **нейтрально**;
4. силуэт руки узнаваем на 5 кадрах В из 5, но для одного seed композиции 384 и 512 не совпадают ни разу.

Объяснение. Время сократилось меньше доли пикселей из-за постоянных накладных расходов; рост энергии границ на исходном размере — эффект масштаба; разные композиции при одном seed — следствие шума другой формы (латент 48×48 вместо 64×64).

Ответ на вопрос варианта. По правилу, записанному до запуска, кадр 384 как черновик чистового кадра 512 не принимается: CLIP и контраст вышли за допуск, хотя и не за разброс между seed. Независимо от метрик кадр 384 не показывает, каким будет чистовой кадр с тем же seed. Уменьшенный кадр годится только для быстрого перебора идей (объект, палитра) в пределах этой модели и брифа. Ответ устойчив к допуску от $\times 0,5$ до $\times 2$. Гипотеза подтвердилась по времени, энергии границ на одном масштабе и узнаваемости объекта, не подтвердилась по CLIP, контрасту и энергии границ на исходном размере.

Демонстрационный вариант воспроизведён (расхождение значений не больше $0,1\%$, выводы совпали по всем метрикам); намеренная ошибка подтверждена: guidance_scale = 1,0 совпадает с 0,0 бит в бит. Вывод относится к SD Turbo закреплённой ревизии, брифу 1, серии seed 101...105 и среде Colab T4 и на другие модели не переносится.

Тезисы для защиты.

1. Изменён один фактор (проверено кодом), допуск записан до запуска (коммит 057583a), серия из пяти seed.
2. Время $-33,7\%$ — единственный эффект, который и значим, и важен; CLIP и контраст вне допуска, но в пределах разброса между seed.
3. Сравнение на одном масштабе показало, что рост энергии границ — эффект масштаба, а не новые детали.

4. Для черновиков решающее наблюдение — разная композиция при одном seed: 384 не предсказывает чистовой кадр 512.

8. Блокнот, паспорт эксперимента и индивидуальный вклад

8.1. Блокнот и артефакты

Блокнот с выводом всех ячеек: <https://github.com/ykvnkm/ai-in-creative-industries/tree/main/LR06> — файл Яковенко_Максим_Михайлович_Вариант_2_ЛР_6.ipynb; там же артефакты `artifacts/comparison.png`, `artifacts/series_seeds.png`, `artifacts/results.json` и журнал `reports/journal.md` с гипотезой, записанной до запуска.

8.2. Паспорт эксперимента

Таблица 14 — Паспорт эксперимента

Поле	Значение
Работа	ЛР 6 «Исследование параметров text-to-image генерации», вариант 2 ($N = 2$: $c = 0$, $k = 1$)
Исполнитель	Яковенко Максим Михайлович, группа Т2БИИКТ-МИК11
Бриф	1, L.BRIEFS[0] (текст — раздел 2.1)
Фактор	size_512_to_384: A — 512×512 , B — 384×384 ; общие условия: тот же запрос, 1 шаг, guidance_scale = 0,0, генератор шума на CPU (свой генератор на изображение)
Серия seed	101...105; прогрев внутри variant_summary — seed 0, в метрики не входит
Модель генерации	stabilityai/sd-turbo, ревизия b261bac6fd2cf515557d5d0707481eafa0485ec2, файлы fp16, вычисления float16; Stability AI Community License
Модель метрики	openai/clip-vit-base-patch32, ревизия 3d74acf9a28c67741b2f4f2ea7635f0aaf6f0268; сходство относительно английского брифа
Метрики	$100 \cdot \cos(\text{CLIP})$; энергия границ (Собель, 1/8); контраст (σ яркости BT.601); время вызова генерации, с; энергия границ и контраст на одном масштабе (Lanczos)
Допуск	CLIP $\pm 1,0$; энергия границ и контраст $\pm 10\%$ от A; время $\pm 20\%$ от A; записан до запуска, коммит 057583a
Критерий значимости	$ \Delta > 2s$, s — выборочное стандартное отклонение (ddof = 1) режима A
Среда	Google Colab, GPU Tesla T4, 2 vCPU, 13 ГБ ОЗУ; Python 3.13.15; torch 2.11.0+cu130; diffusers 0.40.0; transformers 5.16.1; accelerate 1.15.0; numpy 2.1.3; scipy 1.16.3; Pillow 11.3.0; запасной путь CPU не применялся
Библиотеки	1ab05_lib.py 6447 байт, SHA-256 4eb176506585ffcd1702605a767309fb451808229c3622f80ce882b7fa2ce1a; 1ab06_lib.py 6580 байт, SHA-256 c6d8473cf5a3000f4c27fbdef57916c2fbce347db272928d5c4729472f748bd8
Воспроизводимость	повтор seed 101 (A и B) совпал с серией бит в бит: SHA-256 PNG A 84db2534b3e66ea6..., B 256158c9736efe25...; демонстрационный вариант воспроизведён
Артефакты, SHA-256	comparison.png 9643533e755de31b45ad48b16ff19992d179b7e45cb560121bd20939f5129832; series_seeds.png 9a78c05ed98a68654e778afce93a606eda8cf0cd247f82d2a24360af8560dff; results.json 384d96e29bd316022923404f9f0a602a4022546eef9cbd82ea11091e55dfb97e

8.3. Индивидуальный вклад

Работа выполнена мной полностью и самостоятельно: формулировка гипотезы и обоснование допуска до запуска, подготовка ноутбука (контроль версий и целостности библиотек, проверка единственного изменённого фактора, регистратор значений по seed, сравнение на одном масштабе, лист всей серии, проверка чувствительности к допуску, воспроизведение демонстрационного варианта), выполнение в Google Colab, визуальная оценка, анализ, журнал и отчёт. Библиотеки `lab05_lib.py`, `lab06_lib.py` и демонстрационный скрипт `lab06_demo.py` выданы преподавателем и использованы без изменений.

Приложение А. Ответы на контрольные вопросы

Вопросы приведены по разделу 9 методических указаний; ответы опираются на данные настоящей работы.

1. Почему изменяется только один фактор и для чего берётся серия seed

Если изменить два фактора сразу, разницу между режимами нельзя приписать ни одному из них. В работе это проверено кодом: словари А и В различаются только полем `size` (`assert diff == ["size"]`). Серия `seed` нужна, потому что результат одного `seed` смешивает эффект фактора со случайностью начального шума. В этом варианте изменение CLIP по отдельным `seed` — от $-7,46$ (`seed 102`) до $+2,53$ (`seed 104`): по одному `seed` можно было получить и «ухудшение», и «улучшение». Пять `seed` дают среднее и разброс s , с которым сравнивается эффект.

2. Что показывает критерий $|\Delta| > 2s$ и чего он не показывает

Он показывает, выходит ли разность средних за типичный разброс между `seed` в режиме А. Он не показывает, важен ли эффект для задачи (это решает допуск), не говорит, «лучше» ли изображение, и при $n = 5$ сам опирается на грубую оценку s . Пример из варианта: сходство CLIP упало на 2,26 — вне допуска $\pm 1,0$, но $|\Delta|/s = 1,58 < 2$; контраст вырос на 13,7 % — вне допуска ± 10 %, но $|\Delta|/s = 1,17$. Критерий говорит «не значимо», допуск — «практически важно»; вывод — эффект возможен, но пяти `seed` не хватает, чтобы его подтвердить.

3. Что измеряет сходство CLIP и почему оно считается относительно английского брифа

Это косинус угла между векторами изображения и текста в общем пространстве CLIP ViT-B/32, умноженный на 100 (не CLIPScore). Он показывает, насколько изображение близко к тексту с точки зрения CLIP, но не оценивает эстетику и точность деталей; изображение приводится к 224×224 , текст усекается до 77 токенов. Сравнение ведётся с английским брифом, потому что измеряется, насколько результат реализует бриф: если бы эталон менялся вместе с запросом, в эксперименте менялось бы два фактора. В этой работе запрос одинаков в А и В, и в ноутбуке проверено `L.BRIEFS[c] == a_cfg["prompt"]`.

4. Почему рост энергии границ нельзя считать улучшением качества

Энергия границ — средний модуль градиента яркости. Она растёт от любых перепадов: от полезных деталей, но и от шума, артефактов и пересэмплирования. В работе это видно прямо: то же самое изображение А, уменьшенное с 512 до 384, даёт энергию границ на 10,3 % больше — без единой новой детали. Рост $+7,4$ % у режима В на исходном размере при сравнении на одном масштабе превращается в снижение на 2,6 %. В демонстрационном варианте 4 шага удвоили энергию границ при неизменном CLIP.

5. Почему у SD Turbo `guidance_scale = 1,0` не отличается от 0,0 и как это проверить

В Diffusers управление без классификатора включается только при `guidance_scale > 1`; при меньших значениях выполняется один проход сети с текстом. Формально при $w = 1$ смесь $\varepsilon_u + w \cdot (\varepsilon_c - \varepsilon_u)$ и так равна ε_c . Проверка — сравнить SHA-256 изображений при

0,0 и 1,0 и вывести `pipe.do_classifier_free_guidance` после вызова. В работе: SHA-256 совпали, признак False; при 3,0 — True, PSNR относительно 0,0 — 11,61 дБ.

6. Что происходит при размере 768×768 у модели, рекомендованной для 512×512

Это фактор 3, в моём варианте он не выполнялся. Ожидаемо: латент 96×96 больше сетки, на которой модель дистиллирована, поэтому за один шаг она плохо держит композицию — повторяющиеся фрагменты, дублированные объекты (несколько рук или роботов); время растёт примерно пропорционально числу пикселей (в 2,25 раза), внимание — быстрее. В моём варианте выход из рабочего режима был в другую сторону: упрощение деталей, рамки и поля в двух кадрах В из пяти, смещение палитры у одного кадра. Признаки 768 проверяются тем же ноутбуком при N = 3.

7. Изменение времени, если в режиме А 0,30 с, а в режиме В 0,55 с

$(0,55 - 0,30) / 0,30 \cdot 100 \% = 0,25 / 0,30 \cdot 100 \% \approx +83,3 \%$
в этой работе: $(0,1857 - 0,2801) / 0,2801 \cdot 100 \% \approx -33,7 \%$

Рост на 83,3 % выходит за допуск $\pm 20 \%$ и означает «ухудшение» по времени. В моём варианте — снижение на 33,7 %, тоже за допуском, но в сторону «улучшения».

8. Почему сравнение по русскому запросу ведётся относительно английского брифа

Цель метрики — измерить, насколько изображение реализует бриф, а бриф один. Если считать сходство с русским текстом, эталон изменится вместе с фактором, и метрика будет смешивать качество изображения с тем, насколько CLIP понимает русский язык: кодировщик обучен преимущественно на английских текстах, поэтому даже идеальное изображение получит заниженное сходство с русским описанием. Сравнение с английским брифом оставляет эталон неизменным и делает А и В сравнимыми.

9. Как выбран допуск и что изменится, если его удвоить

Допуск записан до запуска (коммит 057583a) и обоснован для каждой метрики (таблица 3): CLIP $\pm 1,0$ — меньше разброса между seed в демонстрационном варианте; энергия границ и контраст $\pm 10 \%$ — граница заметной на глаз разницы, в любую сторону, потому что черновик должен представлять чистовой кадр; время $\pm 20 \%$ — минимальная экономия, ради которой стоит менять размер. При удвоенном допуске (таблица 11): CLIP остаётся «ухудшением» ($2,26 > 2,0$), контраст становится «нейтрально» ($13,7 \% < 20 \%$), время тоже «нейтрально» ($33,7 \% < 40 \%$), энергия границ не меняется. Ответ «не принимается» сохраняется, но меняется его смысл: кадр 384 теряет и практическое преимущество по времени. При допуске $\times 0,5$ к «ухудшениям» добавляется энергия границ.

10. Какие условия из паспорта нужно сохранить, чтобы повторить серию

Модель и ревизию обеих моделей (b261bac6..., 3d74acf9...), файлы fp16 и тип вычислений float16; точный текст брифа; параметры А и В (размер, 1 шаг, `guidance_scale` = 0,0); seed 101...105 и генератор шума на CPU, по генератору на изображение; определения метрик и то, что CLIP считается относительно английского брифа; прогрев перед замерами; допуск и правило 2s; версии torch (с версией CUDA), diffusers и transformers; SHA-256

библиотек; модель GPU. В тех же условиях изображения совпадают бит в бит (повтор seed 101 совпал); на другой видеокарте значения могут отличаться в третьем-четвёртом знаке, а время сравнимо только как отношение В/А — это записывается в паспорт.